



Instituto Tecnológico de Costa Rica

Escuela de Ingeniería en Computación

Bachillerato en Ingeniería en Computación

IC 4302: Base de Datos II

Documentación de la Tarea Programada #2

Pipeline con datos de GDELT

Sofia Elena Barrantes Miranda

2024247378

Daniel Josué Herrera Córdoba

2024082732

Kevin David Jiménez Escalante

2024253395

Abraham Gerardo Solano Parrales

2024132538

San José, Costa Rica


Junio, 2026

Tabla de Contenidos

Enlace al proyecto en el repositorio de Github.....	2
Objetivo del proyecto.....	2
Tecnologías utilizadas.....	3
Arquitectura de la solución y diseño de flujo.....	3
Funcionamiento de cada etapa.....	4
Loader.....	4
Análisis.....	4
Loader a MongoDB.....	6
Capa de Presentación.....	6
Capa final - Orquestación por medio de Airflow.....	6
Modelo agregado de la base de datos MongoDB.....	7
Interpretaciones de las consultas realizadas.....	12
Uso de la Inteligencia Artificial en el proyecto.....	16
Modelos de Inteligencia Artificial utilizados.....	16
Descripción del uso de la Inteligencia Artificial.....	17
Bibliografía.....	18

Enlace al proyecto en el repositorio de Github

Imagen 1 - Proyecto en el repositorio de Github



<https://github.com/Abraham2106/26s1-ic4302-p2>

Objetivo del proyecto

El objetivo del proyecto es crear un pipeline de análisis de datos de GDELT. Para analizar los datos se usa Apache Spark para analizar los datos.

Tecnologías utilizadas



En el proyecto se utilizaron las siguiente tecnologías:

- **Apache Superset:** Crea dashboards interactivos (gráficos, tablas, mapas). Lee los resultados de MongoDB y permite visualizar/explorar los datos sin escribir queries.
- **GDELT Project:** Base de datos pública que publica eventos mundiales (conflictos, cooperaciones, menciones) cada 15 minutos. Vos descargas esos archivos para analizarlos.
- **MongoDB:** Base de datos NoSQL que guarda solo los resultados finales de los análisis (métricas agregadas), no los datos crudos.
- **Apache Spark:** Motor de procesamiento distribuido. Lee los Parquet, calcula los 19 análisis (agregaciones, joins, ventanas) en paralelo usando múltiples workers, y escribe resultados en MongoDB.
- **Apache Parquet:** Formato columnar comprimido para guardar datos. El Loader convierte los JSON crudos de GDELT a Parquet para que Spark los lea rápido.
- **Apache Airflow:** Orquestador de tareas. Dispara el Loader cada 15 min, espera a que descargue datos, luego lanza los jobs de Spark, y después guarda en MongoDB.

Arquitectura de la solución y diseño de flujo

La arquitectura que se propone para el proyecto es la siguiente:

- Loader de Datos
- Análisis de Spark
- Capa de presentación (con MongoDB como base de datos)
- Se valoró utilizar Apache Airflow para el pipeline

Un módulo se encarga de descargar archivos de GDELT usando el archivo índice en la URL "<http://data.gdeltproject.org/gdeltv2/lastupdate.txt>". Primero se descarga este archivo y los archivos comprimidos a los que apunta, después se extraen los datos relevantes en un dataframe y por último se transforman en archivos parquet que se guardan en un directorio durante una hora antes de ser borrados.

Los datos son procesados utilizando Apache Spark, se utiliza esta herramienta porque es un sistema distribuido que ayuda a repartir el trabajo, resultando en mayor eficiencia para procesar grandes flujos de datos. Para este módulo se usa un mini-cluster de

3 nodos, un maestro que se encarga de coordinar a los otros nodos y dos que analizan los datos. De este análisis de datos van a salir los resultados a las 17 consultas solicitadas más las 2 consultas propias.

De todos los datos creados y procesados, únicamente los resultados de las 19 consultas se van a guardar en MongoDB, los archivos parquet se guardan en un directorio temporalmente y las estructuras intermedias se crean y borran en memoria automáticamente. En la siguiente sección de la documentación se entra más en detalle respecto a la base de datos.


Todos estos módulos son orquestados usando Apache Airflow, esta herramienta fué seleccionada puesto que tiene varias ventajas: tiene características resistente a fallos, si algo sale mal, reintenta la operación para prevenir que todo el contenedor deje de funcionar; tiene una interfaz gráfica intuitiva para monitorear el flujo de trabajo; trabaja exclusivamente en python, lo que simplifica su programación y tiene una arquitectura modular que brinda una buena escalabilidad. El módulo de Airflow se divide en varios Grafos acíclicos dirigidos (DAGs por sus siglas in inglés) y consiste en una para cada sección del pipeline, uno para el loader, otro para Spark y otro para mongoDB.

Funcionamiento de cada etapa

Loader

Paso 1: Loader

Imagen 2 - Loader




Fuente: Elaboración propia con Mermaid

Se conecta a GDELT y baja los siguientes archivos: Events table, Mentions table y GKG. Esto se debe hacer cada 15 minutos de forma continua, manteniendo únicamente los datos RAW del período que el equipo decida (por ejemplo, la última hora), dado el volumen de información que genera GDELT. Internamente el Loader también se encarga de transformar los archivos .csv descargados a .parquet antes de escribirlos a disco, eliminando la necesidad de un paso de transformación separado.

En la URL "<http://data.gdeltproject.org/gdeltv2/lastupdate.txt>" se encuentra un archivo índice que contiene los tres archivos solicitados, mediante Airflow se llaman las funciones main y borrar_parquets_raw. La función main descarga los archivos del índice y los convierte en archivos parquet, los archivos se guardan en un directorio durante una hora para ser analizados, pero borrar_parquets_raw se encarga de eliminar los archivos para no acumular espacio en disco.

Análisis

Paso 2: + Spark (Análisis)

Imagen 3 - Diagrama de Spark

Fuente: Elaboración propia con Mermaid

Ya contando con los datos, se realiza el análisis, usando Spark leyendo los archivos Parquet.

17 consultas a analizar

1. Mapa de calor de intensidad de conflictos por país por día (escala Goldstein)
2. Top 10 países que generan más eventos noticiosos por día
3. Correlación AvgTone vs número de fuentes
4. Distribución de tipos de eventos CAMEO por región
5. Matriz de interacción entre tipos de actores (gob vs militar vs rebeldes)
6. Países con mayor cobertura mediática por evento
7. Tendencia de sentimiento por país en el tiempo (promedio móvil Avg Tune)
8. Pares de países que más entran en conflicto
9. Detección de escalada de eventos (aumento acelerado de menciones en 24h)
10. Agrupamiento de eventos de conflicto por religión por región
11. Principales temas del GKG por continente por año
12. Organizaciones más mencionadas globalmente por día
13. Análisis de rezago: el tono de hoy predice el conflicto de mañana?
14. Grafo de red diplomacia vs conflictos entre países
15. Índice de diversidad de fuentes por país
16. Frecuencia de conflictos por etnia de los actores
17. Detección de breaking news (0 a 100+ menciones en <1h)
18. EXTRA 1. Distribución de eventos positivos y negativos
19. EXTRA 2. Top 10 países menos noticiosos

Cómo Spark lee datos de Parquet

Spark nunca escribe datos a como vienen sino que solo escribe resultados de los análisis que hizo.

Cada análisis está como un archivo .py separado dentro de la carpeta jobs/.

```
df = spark.read.parquet(f"{DATA_PATH}/{table}.parquet")
```

Como Parquet es de formato columnar (a diferencia de CSV) entonces en vez de guardar los datos fila por fila, los guarda columna por columna. Parquet ya trae "etiquetado" qué tipo de dato es cada columna (número, texto, fecha, etc) dentro del mismo archivo y así Spark no tiene que adivinar.

Entonces: `spark.read.parquet(...)` Spark no lee nada todavía. Espera el resultado de verdad como con `.show()` o `.count()`.


En resumen, Spark realiza esto:

1. Leer (`spark.read.parquet`)
2. Transformar (`filter`, `groupBy`, `join`, `explode`, `Window`) (nunca tocan datos hasta acción las dispara]
3. Actuar (`.show()`, `count()`).

Loader a MongoDB

Paso 3: + MongoDB (Loader a Mongo)

Imagen 4 - Diagrama de MongoDB



Fuente: Elaboración propia con Mermaid

Cada uno de los 19 análisis (17 + 2) tiene su propia colección en MongoDB, ya con el resultado calculado (no datos crudos), para que Superset solo tenga que leer y graficar sin tener que procesar nada.

Se definen los nombres de colecciones, la estructura de documentos por cada análisis ya que no todos son iguales, unos son series de tiempo, otros son rankings y otros son matrices/grafos.

Capa de Presentación

Paso 4: + Capa de Presentación (pipeline completo)

Se tomó como decisión usar Apache Superset conectado a MongoDB (o lo que termine siendo el datasource final y se revisa en caso de que Superset extrae bien de MongoDB directamente o si se necesita un elemento intermedio).

Se muestra los 19 análisis con su gráfico/tabla correspondiente, en una o varias páginas/dashboards sin drill downs

Imagen 5 - Dashboard de Superset




Fuente: Elaboración propia con Apache Superset

Se analiza en detalle cada consulta en la sección de Interpretaciones de las consultas realizadas.

Capa final - Orquestación por medio de Airflow

Diagrama final: pipeline completo con Airflow como orquestador

Imagen 6 - Diagrama de Airflow



Fuente: Elaboración propia con Mermaid

Nota: las flechas sólidas son flujo de datos, las punteadas son orquestación (Airflow no mueve los datos, solo dispara/coordina cada paso).

Modelo agregado de la base de datos MongoDB

La siguiente es el modelo agregado de cada consulta guardada con datos ya calculados en MongoDB. Esta tecnología se utiliza únicamente para almacenar los resultados ya procesados. Los datos crudos provenientes de GDELT se mantienen en archivos Parquet para no ser insertados en MongoDB. Se tiene una colección por análisis para poder consultar directamente los resultados sin procesar crudos.

Mapa de calor de intensidad de conflictos por país por día en escala Goldstein:


```
heatmap_conflictos
{
  "_id": "",
  "fecha": 20260620, "pais": "",
  "intensidad_promedio_conflicto": "",
  "total_eventos_conflicto": ""
}
```

Indice:

```
db.heatmap_conflictos.createIndex({ fecha: 1, pais: 1
})
```

Top 10 países que generan más eventos noticiosos por día:

```
top10_paises_eventos_dia
{
  "_id": "",
  "fecha": 20260620, "pais": "",
  "total_eventos_noticiosos": "",
  "ranking": ""
}
```

Indice:

```
db.top10_paises_eventos_dia.createIndex({ fecha: 1,
ranking: 1 })
```

Correlación entre el tono promedio y el número de fuentes noticiosas que cubren un evento:

```
correlacion_avgtone_fuentes
{
  "_id": "",
  "correlacion_avgtone_fuentes": "",
  "total_eventos_analizados": "",
  "promedio_avgtone": "",
  "promedio_fuentes": ""
}
```

Indice:

```
db.correlacion_avgtone_fuentes.createIndex({
total_eventos_analizados: 1 })
```

Distribución de tipos de eventos CAMEO por región del mundo:

```
cameo_region_mundo
{
  "_id": "",
  "region_mundo": "",
  "eventrootcode": "",
  "total_eventos": ""
}
```

Indice:

```
db.cameo_region_mundo.createIndex({ region_mundo: 1,
eventrootcode: 1 })
```

Matriz de interacción entre tipos de actores:

```
matriz_interaccion_actores
{
  "_id": "",
  "actor_origen": "",
  "actor_destino": "",
  "frecuencia_interaccion": ""
}
```

```
}
```

Indice:

```
db.matriz_interaccion_actores.createIndex({
actor_origen: 1, actor_destino: 1 })
```

Países con mayor cobertura mediática por evento:

```
cobertura_mediativa_pais
{
  "_id": "",
  "pais": "",
  "total_eventos": "",
  "total_menciones": "",
  "razon_menciones_por_evento": ""
}
```

Indice:

```
db.cobertura_mediativa_pais.createIndex({ pais: 1,
razon_menciones_por_evento: -1 })
```

Tendencia de sentimiento por país a lo largo del tiempo:

```
tendencia_sentimiento_pais
{
  "_id": "",
  "fecha": "",
  "pais": "",
  "avg_tone_diario": "",
  "total_eventos": ""
}
```

Indice:

```
db.tendencia_sentimiento_pais.createIndex({ pais: 1,
fecha: 1 })
```

Conflictos entre actores:

```
conflictos_pares_paises
{
  "_id": "",
  "pais_a": "",
  "pais_b": "",
  "frecuencia_conflicto": "",
  "intensidad_promedio_goldstein": "",
  "mayor_intensidad_conflicto": ""
}
```

Indice:

```
db.conflictos_pares_paises.createIndex({ pais_a: 1,
pais_b: 1 })
```

Detección de escalada de eventos:

```
escalada_eventos_1h
{
  "_id": "",
  "globaleventid": "",
  "dia": "",
  "menciones_24h": "",
  "menciones_24h_antes": "",
  "aumento_24h": "",
  "factor_crecimiento_24h": ""
}
```

```
}
```

Indice:

```
db.escalada_eventos_1h.createIndex({ globaleventid:
1, hora: 1 })
```

Conflictos agrupados por religión y por región geográfica:

```
conflictos_religion_region
{
  "_id": "",
  "region_mundo": "",
  "religion": "",
  "total_eventos_conflicto": "",
  "intensidad_promedio_conflicto": ""
}
```

Indice:

```
db.conflictos_religion_region.createIndex({
region_mundo: 1, religion: 1 })
```

Principales temas extraídos por el GKG por continente por año:

```
top_temas_continente_anio
{
  "_id": "",
  "region_mundo": "",
  "anio": "",
  "tema": "",
  "frecuencia": "",
  "ranking": ""
}
```

Indice:

```
db.top_temas_continente_anio.createIndex({
region_mundo: 1, anio: 1, ranking: 1 })
```

Organizaciones más mencionadas a nivel global por día:

```
top_organizaciones_global_dia
{
  "_id": "",
  "fecha": "",
  "organizacion": "",
  "total_menciones": "",
  "ranking": ""
}
```

Indice:

```
db.top_organizaciones_global_dia.createIndex({ fecha:
1, ranking: 1 })
```

Análisis de rezago:

```
tono_conflicto_ventana
{
  "_id": "" ,
  "fecha": "" ,
  "tono_promedio_hoy": "" ,
  "conflictos_hoy": "" ,
  "conflictos_manana": ""
}
```

Indice:

```
db.tono_conflicto_ventana.createIndex({ fecha: 1 })
```

Correlación del tono con los conflictos:

```
correlacion_tono_conflicto_ventana
{
  "_id": "",
  "correlacion_tono_hoy_conflicto_manana": "",
  "total_datos_analizados": ""
}
```

Índice:

```
db.correlacion_tono_conflicto_ventana.createIndex({
total_ventanas_analizadas: 1 })
```

Grafo de red de interacciones entre países:

```
grafo_interacciones_paises
{
  "_id": "",
  "pais_origen": "",
  "pais_destino": "",
  "tipo_relacion": "",
  "peso_arista": "",
  "goldstein_promedio": ""
}
```

Índice:

```
db.grafo_interacciones_paises.createIndex({
pais_origen: 1, pais_destino: 1, tipo_relacion: 1 })
```

Índice de diversidad de fuentes por país:

```
diversidad_fuentes_pais
{
  "_id": "",
  "pais": "",
  "medios_distintos": "",
  "total_menciones": "",
  "total_eventos": "",
  "indice_diversidad_fuentes": ""
}
```

Índice:

```
db.diversidad_fuentes_pais.createIndex({ pais: 1,
medios_distintos: -1 })
```

Frecuencia de conflictos por etnia de los actores:

```
frecuencia_conflictos_etnia
{
  "_id": "" ,
  "etnia": "",
  "frecuencia_conflictos": "" ,
  "intensidad_promedio_conflicto": "",
  "maxima_intensidad_conflicto": ""
}
```

Índice:

```
db.frecuencia_conflictos_etnia.createIndex({ etnia:
1, frecuencia_conflictos: -1 })
```

Detección de noticias de última hora:

```

breaking_news_ultima_hora
{
  "_id": "",
  "globaleventid": "",
  "hora": "",
  "menciones_en_hora": "",
  "menciones_hora_anterior": ""
}

```

Indice:

```

db.breaking_news_ultima_hora.createIndex({
globaleventid: 1, hora: 1 })

```

Proporción de eventos positivos y negativos:

```

eventos_positivos_negativos
{
  "_id": "",
  "tipo_eventos": "",
  "count": ""
}

```

Indice:

```

db.eventos_positivos_negativos.createIndex({
tipo_evento: 1 })

```

Países menos noticiosos:

```

top10_paises_menos_noticiosos
{
  "_id": "",
  "pais": "",
  "total_eventos": "",
  "ranking": ""
}

```

Indice:

```

db.top10_paises_menos_noticiosos.createIndex({ pais:
1, total_eventos: 1 })

```

Los índices se encuentran en el archivo indexes.js son para acelerar consultas por fecha, país, región, ranking, pares de países y eventos por hora.

Interpretaciones y conclusiones de las consultas realizadas

En esta sección se adjunta una screenshot de cada gráfico del dashboard realizado en Apache Superset para su análisis. El análisis se realizó el día martes 23 de junio del 2026 con los datos capturados.


Imagen 7 - #1 Mapa de calor de intensidad de conflictos por país por día (escala Goldstein)



Fuente: Elaboración propia con Apache Superset

El mapa anterior muestra que la mayoría de los países analizados tienen conflictos de intensidad moderada a alta según la escala Goldstein, con valores que oscilan principalmente entre -2 y -6. SF destaca como el caso más extremo con -8.67, aunque registró una ligera mejora al pasar a -7.8 en la fecha posterior. Por el contrario, AS presenta el nivel de conflicto más bajo de todo el grupo con -1.3.


Imagen 8 - #2 Top 10 países que generan más eventos noticiosos por día



Fuente: Elaboración propia con Apache Superset


La imagen 8 muestra que Estados Unidos (US) lidera con una enorme diferencia, generando 136 eventos noticiosos, casi tres veces más que el segundo país. El resto del top 10 está mucho más parejo, con valores entre 23 y 47 eventos, lo que indica que la concentración de noticias es muy alta en un solo país.

Imagen 9 - #3 Correlación AvgTone vs número de fuentes



Fuente: Elaboración propia con Apache Superset


Ese número indica que no hay prácticamente relación entre el tono de las noticias y cuántas fuentes las cubren. Es una correlación tan cercana a cero que, en la práctica significa que una variable no predice nada de la otra.

Imagen 10 - #4 Distribución de tipos de eventos CAMEO por región

Fuente: Elaboración propia con Apache Superset

En la imagen anterior se ve que Asia concentra la mayor cantidad de eventos CAMEO por mucho, con más del doble que Europa y casi el triple que África. Norteamérica y Medio Oriente le siguen como las regiones con más actividad, mientras que Sudamérica y Oceanía registran los volúmenes más bajos del grupo.


Imagen 11 - #5 Matriz de interacción entre tipos de actores (gob vs militar vs rebeldes)



Fuente: Elaboración propia con Apache Superset

En la matriz se puede ver que el gobierno **GOV** es el actor más activo de la red, con las interacciones más intensas tanto internamente (GOV-GOV) como con la oposición (**GOV-OPP**). El **militar** y la **policía** también muestran vínculos importantes. En cambio, actores como **sociedad civil**, **medios** y **empresas** tienen una presencia mucho menor en la matriz, puede ser que los conflictos recogidos giran principalmente en torno al Estado y sus actores armados.


Imagen 12 - #6 Países con mayor cobertura mediática por evento



Fuente: Elaboración propia con Apache Superset


Como se puede apreciar en la imagen anterior el país Camerún es el país más cubierto mediáticamente en este momento por su compleja crisis sociopolítica ya que el continente de África sufre de muchos conflictos y corrupción.

Imagen 13 - #7 Tendencia de sentimiento por país en el tiempo (promedio móvil AvgTone)



Fuente: Elaboración propia con Apache Superset


Imagen 14 - #8 Pares de países que más entran en conflicto



Fuente: Elaboración propia con Apache Superset

Los conflictos más intensos se concentran en los pares ISR-USA e IRN-USA, que lideran con valores cercanos a 4, lo que sitúa a Estados Unidos como actor central en las tensiones registradas. Y otros pares como GBR-USA o FRA-USA muestran niveles de conflictividad mucho más bajos.

Imagen 15 - #9 Detección de escalada de eventos



Fuente: Elaboración propia con Apache Superset

Imagen 16 - #10 Agrupamiento de eventos de conflicto basados en religión por región geográfica



Fuente: Elaboración propia con Apache Superset

Imagen 17 - #11 Principales temas del GKG por continente por año




Fuente: Elaboración propia con Apache Superset

Como se puede ver en la imagen 17, Norteamérica concentra la mayoría de los temas del GKG (7.37 mil), más que Asia, Europa y Medio Oriente juntos, lo que muestra un claro sesgo de cobertura hacia Estados Unidos y Canadá. El tema TAX_FNCACT (actores institucionales) domina en casi todos los

continentes. África, Oceanía y Sudamérica aparecen con una presencia mucho menor lo que refleja que la información del GKG está muy desbalanceada hacia el hemisferio norte.

Imagen 18 - #12 Organizaciones más mencionadas globalmente por día



Fuente: Elaboración propia con Apache Superset


Como se puede apreciar en la Imagen 18, Estados Unidos aparece como la "organización" más mencionada por muchos. La lista está dominada por grandes tecnológicas como Instagram, Google, Facebook, Tesla, SpaceX y actores políticos o mediáticos como White House, Supreme Court, Associated Press, lo que se puede interpretar que la mayoría de eventos noticiosos giran en torno al poder estadounidense y sus empresas globales.

Imagen 19 - #13 Análisis de rezago: ¿el tono de hoy predice el conflicto de mañana?


Fuente: Elaboración propia con Apache Superset

Imagen 20 - #14 Grafo de red diplomacia vs conflictos entre países

14. relaciones conflicto




14. relaciones diplomaticas



Fuente: Elaboración propia con Apache Superset


Como se puede observar, el conflicto reciente entre Irán (IRN) y Estados Unidos (USA) está quedando registrado en el diagrama circular. Los países de Medio Oriente y Asia aparecen muy vinculados a estos dos polos y mientras que Europa y América Latina ocupan posiciones más lejanas con menos interacciones.

Imagen 21 - #15 Índice de diversidad de fuentes por país



Fuente: Elaboración propia con Apache Superset

Imagen 22 - #16 Frecuencia de conflictos por etnia de los actores




Fuente: Elaboración propia con Apache Superset

En la imagen 22 se puede ver que Los kurdos y los palestinos lideran la lista con la mayor frecuencia de conflictos. La mayoría de los grupos más conflictivos provienen de Asia del Sur, Medio Oriente y África, mientras que pueblos como los mapuche o los karen aparecen con niveles mucho más bajos. Esto se puede interpretar como que los conflictos étnicos más visibles en los datos se concentran en regiones con tensiones que duran más que los demás.

Imagen 23 - #17 Detección de breaking news (0 a 100+ menciones en <1h)

11. breaking news última hora


:



Fuente: Elaboración propia con Apache Superset

En la imagen 23, los eventos detectados como breaking news acumularon entre 3,800 y 12,500 menciones en apenas una hora lo que indica que noticias de mucho impacto se viralizaron de forma explosiva. Esto puede significar que hubo al menos una noticia de enorme trascendencia global en ese momento junto con otras no tan importantes pero aún significativas.


Imagen 24 - # EXTRA 1. Distribución de eventos positivos y negativos



Fuente: Elaboración propia con Apache Superset

En la imagen 24, la gran mayoría de los eventos registrados son de cooperación mientras que los eventos de conflicto representan apenas una cuarta parte. Esto puede indicar que los datos reflejan muchas más interacciones positivas y diplomáticas que conflictos.

Imagen 25 - # EXTRA 2. Top 10 países menos noticiosos



Fuente: Elaboración propia con Apache Superset

Como se puede ver en la imagen 25, varios de estos países son pequeños y tienen una población baja como Guinea Ecuatorial (GQ), Brunéi (BU) o Jordania (JO). Aunque no hay diferencia entre ellos en cuanto a cobertura se mezcla naciones de distintas regiones y tamaños como Venezuela, Polonia, Burundi, entre otros. Esto se debe probablemente a una cobertura mediática muy limitada o a la ausencia de eventos reportados en el período en que se analizaron los datos.

Uso de la Inteligencia Artificial en el proyecto

La Inteligencia Artificial (IA) fue utilizada para una variedad de tareas. Se realizó un uso justo y parcial de la IA en la tarea programada.

Modelos de Inteligencia Artificial utilizados

- *Claude Sonnet 4.6*. Usada para generación de código para el pipeline y depuración de código.

- *ChatGPT GPT-5*. Uso de plan personal gratuito principalmente para depuración de código, aclarar dudas y proveer feedback sobre tecnologías instaladas en el proyecto.
- Github Copilot. Para creación de Github Action de creación de sprints, Todos y requerimientos

Descripción del uso de la Inteligencia Artificial

Tabla 1 – Descripción del uso de la Inteligencia Artificial

Cómo se generó	Herramienta usada	Qué generó
Creación de script para Automatización de proyectos Scrum con GitHub Actions.	<i>Claude Sonnet 4.6</i> , Github Copilot	Pipeline con spec/historias → script en Actions (Node+Octokit o Python+PyGithub) que opcionalmente llama a un LLM para estructurar el texto libre en issues → API de GitHub crea milestones, labels e issues → (fase 2, opcional) asigna los issues triviales y bien definidos a Copilot coding agent para que abra PRs solo, mientras el equipo se enfoca en lo que sí quiere aprender a programar. Se creó un archivo .yaml para creación de sprints, Todos y requerimientos. Estos archivos fueron supervisados por el equipo
Prompt con petición de ideas y estructura de consultas en Python para poder crear los datasets y poder guardar en MongoDB los datos ya calculados. Además de creación de jobs de Spark desde 0.	<i>Claude Sonnet 4.6</i>	Se generó un folder con jobs con los archivos analytics .py, algunos ejemplo en example_queries y verify_cluster .py. Estos archivos fueron supervisados por el equipo.
Con un prompt específico incorporadas para Construcción de Apache Superset desde 0	<i>Claude Sonnet 4.6</i>	Se generó un folder con el init (create_datasets.py, superset-init.sh) junto con el Dockerfile y superset_config. Estos archivos fueron supervisados por el equipo

Prompt para revisar y arreglar bugs de código en el Loader	ChatGPT GPT-5., Claude Sonnet 4.6	Se generaron archivos .py con el código con bugs solucionados y mejoras no vistas por el equipo.
--	-----------------------------------	--

Bibliografía

- Borthakur, D. (s.f.) *HDFS Architecture Guide*, hadoop. Available at: https://hadoop.apache.org/docs/r1.2.1/hdfs_design.html
- Google Cloud (2025), *Google Cloud Serverless for Apache Spark: high-performance, unified with BigQuery*, Google Cloud. Available at <https://cloud.google.com/blog/products/data-analytics/introducing-google-cloud-serverless-for-apache-spark-in-bigquery>
- The Apache Software Foundation (s.f). *apache-airflow-providers-docker*, Apache Airflow. Available at: <https://airflow.apache.org/docs/apache-airflow-providers-docker/stable/index.html>
- The Apache Software Foundation (s.f). *Airflow 101: Building Your First Workflow*, Apache Airflow. Available at: <https://airflow.apache.org/docs/apache-airflow-providers-docker/stable/index.html>
- The Apache Software Foundation (s.f). *Scheduler*, Apache Airflow. Available at: <https://airflow.apache.org/docs/apache-airflow/stable/administration-and-deployment/scheduler.html>
- The GDELT project*. (s.f.). *The GDELT Project*. Available at: <https://www.gdeltproject.org/>